

프로젝트 2차 보고서

멀티모달 딥러닝 기반 지진 PGV 추정 및 위험지도 시각화
(Multimodal Deep Learning-Based PGV Estimation and
Earthquake Hazard Mapping)



연구트랙 26팀 TriAI

지도교수 이형준

2371062 조혜림 · 2371012 김민 · 2371031 박소영

목차

I Team Info	3
1. 과제명	3
2. 팀 정보	3
3. 팀 구성원	3
II Project-Summary	4
1. 문제 정의	4
2. 기존 연구와의 비교	4
2.1 단일 모달리티 기반 PGV 예측 연구	4
2.2 멀티모달 딥러닝 기반 이벤트 분류/규모 추정 연구	5
2.3 기존 연구와의 차이점	5
3. 제안 내용	5
4. 기대 효과 및 의의	6
4.1 고정밀도 PGV 추정	6
4.2 미계측 지역 보간 및 시각화	6
4.3 멀티모달 딥러닝 기반 PGV 추정 아키텍처 제안	6
4.4 지진 대응의 실무 활용성	6
5. 주요 기능 리스트	7
5.1 모달리티별 인코더 설계	7
5.2 UMIS	7
5.3 후처리	7
III Project-Design	8
1. 요구사항 정의	8
1.1 입력 최적화를 위한 전처리 파라미터 비교 실험	8
1.2 멀티모달 대 단일모달리티 성능 비교 실험	8
1.3 지반 보정 및 공간 보간 유효성 검증	8
2. 전체 시스템 구성	9
2.1 데이터	9
2.2 전처리	9
2.3 전체 아키텍처	10
2.4 모듈별 상세 설계	11
3. 과제의 산출물	13
3.1 UMIS 기반 멀티모달 딥러닝 아키텍처	13
3.2 딥러닝 기반 ShakeMap 시각화	13
3.3 멀티모달 성능 검증 및 단일모달과의 비교 분석	14
4. 실험	14
4.1 방법	14
4.2 결과	15
5. 결론	16

I . Team Info

1. 과제명

멀티모달 딥러닝 기반 지진 PGV 추정 및 위험지도 시각화

Multimodal Deep Learning-Based PGV Estimation and Earthquake Hazard Mapping

2. 팀 정보

- 팀 번호: 26
- 팀 이름: TriAI

3. 팀 구성원

이름	학번	역할
조혜림	2371062	리더, 데이터 수집 및 전처리, 서류 메인 관리, 디코더 설계, 멀티모달 모델 설계, 학습 및 검증
김 민	2371012	팀원, 데이터 수집 및 전처리, 깃허브 메인 관리, 지진파형 모델 설계, 학습 및 검증
박소영	2371031	팀원, 데이터 수집 및 전처리, 노션 메인 관리, GNSS 모델 설계, 학습 및 검증

II. Project-Summary

1. 문제 정의

기존의 지진 위험도 분석 방법으로는 ShakeMap과 PSHA가 널리 사용되고 있다. ShakeMap은 지진 발생 이후 지진계에서 관측된 데이터를 기반으로 특정 지역의 지반 흔들림 강도를 지도 형태로 시각화하는 방법으로, 실제 지진 이벤트에 대한 공간적 분포를 직관적으로 파악할 수 있다는 장점이 있다. 그러나 관측 데이터가 존재하지 않는 지역에 대해서는 경험적 지반운동 예측식(GMPE)에 의존하여 값을 보완하기 때문에, 센서 분포가 불균형한 경우 공간적 정확도가 저하될 수 있다. 또한 ShakeMap은 지진 발생 이후에만 생성 가능한 사후 분석 도구로서, 실시간 예측이나 조기 대응 시스템으로 활용하는 데에는 한계가 있다.

PSHA(Probabilistic Seismic Hazard Analysis)는 특정 지역에서 일정 기간 동안 발생할 수 있는 지진으로 인한 지반 흔들림의 크기를 확률적으로 추정하는 방법으로, 장기적인 지진 위험도 평가 및 내진 설계 기준 수립에 활용된다. 하지만 PSHA는 과거 지진 기록과 단층 정보, 그리고 GMPE와 같은 물리-통계 기반 모델에 크게 의존하기 때문에, 실제 지진 발생 시 나타나는 비선형적이고 복잡한 시공간적 패턴을 충분히 반영하기 어렵다. 특히 개별 지진 이벤트에 따른 지역적 특성이나 다양한 관측 데이터 간의 상호작용을 고려하지 못한다는 한계가 존재한다.

딥러닝 기반 지진 분석 연구의 경우에도, 주로 지진파형 데이터와 같은 단일 모달리티에 기반하거나 제한적인 관측 정보를 활용하는 경우가 많아 지반 변형을 나타내는 주요 지표인 PGV를 정밀하게 추정하기 어렵다. 또한 미계측 지역에서의 관측 공백으로 공간적 연속성이 저하되어, 전체적인 위험도 추정의 불확실성을 증가시키는 요인으로 작용한다.

따라서 기존의 물리수식 기반 분석 방식과 딥러닝 기반 분석 연구는 실제 지진의 복잡한 특성을 충분히 반영하지 못하므로, 다양한 관측 데이터를 통합적으로 활용하여 보다 정밀하고 신뢰성 있는 지진 위험도 추정이 필요하다.

본 연구의 목표는 지진파형 데이터와 GNSS 데이터를 통합적으로 활용하는 멀티모달 딥러닝 모델을 통해 지반 변형을 나타내는 주요 지표인 PGV(최대지반속도)를 보다 정밀하게 추정하는 것을 목표로 한다. 또한 다양한 관측 데이터를 통합하여 기존 방법의 한계를 극복하고, 신뢰성 있는 지진 위험도 수치를 추정하고자 한다.

2. 기존 연구와의 비교

2.1. 단일 모달리티 기반 PGV 예측 연구

- (1) Liu, J., Ma, Q., & Xie, Q. (2025). A Deep Learning Model for On-Site PGV Prediction in Earthquake Early Warning Integrating Prior Knowledge. In Proceedings of the 2025 5th International Conference on Internet of Things and Machine Learning (IoTML '25), 80-84. Association for Computing Machinery. <https://doi.org/10.1145/3749566.3749585>
- (2) Gao, Z., Li, Y., Shan, X., & Zhu, C. (2021). Earthquake Magnitude Estimation

from High-Rate GNSS Data: A Case Study of the 2021 Mw 7.3 Maduo Earthquake. *Remote Sensing*, 13(21), 4478. <https://doi.org/10.3390/rs13214478>

기존의 PGV 예측 연구는 주로 단일 모달리티 데이터를 기반으로 수행되어 왔다. (1)의 연구에서는 지진파형 데이터를 입력으로 활용하여 딥러닝 기반으로 PGV를 예측하는 모델을 제안한다. 이 모델은 지진파형의 시각적 특성을 효과적으로 학습하여 실시간 예측이 가능하다는 장점이 있다. 그러나 지진파형 데이터만을 활용하기 때문에 실제 지표 변형을 직접적으로 반영하지 못하며, 단일 센서 기반 입력으로 인해 정보가 제한된다는 한계가 존재한다.

(2)의 연구에서는 고속 GNSS 데이터를 활용하여 지진 규모를 추정하는 방법을 제안하였다. 이 방법은 GNSS 데이터를 통해 지반의 실제 변위를 직접 반영할 수 있다는 장점이 있으며, 특히 대규모 지진에서 신뢰도 높은 정보를 제공할 수 있다. 그러나 GNSS 데이터는 샘플링 속도가 상대적으로 낮아 고주파 성분을 충분히 반영하지 못하며, 노이즈에 민감하여 단독으로는 정밀한 PGV 추정에 한계가 존재한다.

2.2. 멀티모달 딥러닝 기반 이벤트 분류/규모 추정 연구

- Zhu, J., Li, S. & Song, J. Multimodal deep learning network for fast seismic discrimination and magnitude classification. *Geosci. Lett.* 12, 39 (2025). <https://doi.org/10.1186/s40562-025-00412-7>.

최근에는 서로 다른 데이터 소스를 결합하여 활용하려는 멀티모달 접근이 일부 연구에서 시도되고 있다. 해당 연구에서는 다양한 입력 데이터를 활용한 딥러닝 모델을 제안했다. 이 모델은 서로 다른 데이터 간의 보완적인 정보를 활용할 수 있다는 장점이 있지만, 이벤트 분류나 규모 추정 중심이며 PGV와 같은 연속적인 지반 운동 값을 직접 예측하는 데에는 적용되지 않았다. 또한 대부분의 기존 멀티모달 연구는 데이터를 단순히 결합하는 수준에 머물러 있어, 모달리티 간의 상호작용을 효과적으로 학습하지 못한다는 한계가 있다.

2.3. 기존 연구와의 차별점

따라서 기존 연구들은 단일 모달리티에 의존하거나, 멀티모달 데이터를 활용하더라도 통합 방식이 제한적이고 실제 지반 변형을 정밀하게 반영하는 PGV 예측에는 여전히 한계가 존재한다. 이에 본 연구에서는 지진파형 데이터와 GNSS 데이터를 통합적으로 활용하고, 이를 공통 표현 공간으로 투영하여 학습하는 멀티모달 딥러닝 모델을 제안함으로써, 기존 연구의 한계를 극복하고 보다 정밀한 PGV 예측을 수행하고자 한다.

3. 제안 내용

기존 지진 위험도 분석 방법이 가지는 단일 모달리티 의존, 멀티모달 데이터의 상호작용 미반영 등으로 인한 PGV 정밀 추정의 한계를 해결하기 위해 본 연구에서는 지진파형 데이터와 GNSS 데이터를 통합적으로 활용하는 멀티모달 딥러닝 기반 PGV 예측 모델을 제안한다.

지진파형과 GNSS에 대한 전용 인코더를 사용해, 각 모달리티의 독립적인 특성을 효과적으로 추출한다. 이후 서로 다른 모달리티에서 추출된 특징을 UMIS((Universal Modality-Indep

endent Space)로 투영하여, 시공간적인 결합과 두 모달리티의 깊은 상호작용을 학습한다.

통합된 표현을 디코더에 입력해 회귀분석으로 PGV를 추정하여, 단일 모달리티 기반 접근보다 정밀한 지반 운동 추정을 가능하게 한다. 특히 본 모델은 지진파형의 시간적 특성과 GNSS의 실제 변위 정보를 동시에 반영함으로써, 기존 방법의 한계를 보완하고 신뢰성 높은 PGV 추정을 수행할 수 있도록 설계하였다.

또한 추정된 PGV를 기반으로 후처리(post-processing) 작업을 수행한다. 먼저, Vs30 지반 데이터와의 연계를 통해 지역별 지반 특성을 반영하여 현실적인 지반 운동 정보를 생성한다. 또한 센서가 설치되지 않은 지역에 대해서는 크리깅(kriging) 기법을 활용하여 공간적 보간을 수행함으로써 관측 공백을 보완한다. 마지막으로, 이러한 과정을 통해 생성된 PGV 분포를 ShakeMap 형태로 시각화하여 지진 위험도를 직관적으로 표현할 수 있도록 한다.

마지막으로, 본 연구에서는 제안한 멀티모달 모델의 성능을 검증하기 위해, 동일한 데이터셋을 기반으로 지진파형 및 GNSS 단일 모달리티 모델과의 비교 실험을 수행한다. 이를 통해 멀티모달 접근의 효과와 성능 향상을 정량적으로 분석한다.

4. 기대 효과 및 의의

4.1. 고정밀도 PGV 추정

멀티모달 딥러닝 모델을 기반으로 PGV를 추정하여, 기존 단일 모달리티 모델보다 복잡한 지진 패턴을 파악하여 관측소별 PGV 값을 추정한다. 또한 Vs30 지반 데이터를 연계를 통한 지반 증폭 지수를 반영으로, 정확하고 정밀한 PGV 값을 추정해 지진 위험도 평가의 신뢰성을 향상시킨다.

4.2. 미계측 지역 보간 및 시각화

크리깅(Kriging) 기반 공간 보간을 통해, 미계측 지역까지 포함한 연속적인 PGV 분포를 생성한다. 이를 시각화하여 ShapeMap 형태의 지진 위험도 지도를 생성한다. 이는 기존 ShakeMap 기반 방법의 공간적 한계를 보완하고, 현실적인 위험도 시각화를 가능하게 한다.

4.3. 멀티모달 딥러닝 기반 PGV 추정 아키텍처 제안

본 연구는 지진파형-GNSS 통합의 새로운 멀티모달 딥러닝 아키텍처를 제안한다. 해당 아키텍처는 UMIS Layer를 포함하여, 지진파형과 GNSS 데이터 간의 상호작용을 효과적으로 학습할 수 있는 새로운 접근 방식을 제시한다는 점에서 학문적 의의를 가진다. 이러한 접근은 향후 다양한 지구물리 데이터 통합 연구로 확장될 수 있는 기반을 제공할 것으로 기대된다.

4.4. 지진 대응의 실무 활용성

ShakeMap 형태의 지진 위험도 지도는 실무에 활용될 가능성을 가진다. 지진 조기 경보 시스템(Earthquake Early Warning) 및 재난 대응 시스템에서 보다 신속하고 정확한 의사결정을 지원할 수 있으며, 인프라 안전 관리 및 지진 위험도 분석 분야에서도 활용될 수 있다.

5. 주요 기능 리스트

5.1. 모달리티별 인코더 설계

지진파형과 GNSS 데이터를 각각 별도의 인코더에 입력하여 특징을 추출한다. 지진파형의 경우 EQTransformer의 구조를 차용하여 인코더를 설계하였다. GNSS의 경우에는 지진파형과 달리 저주파라는 고유한 특성에 맞게 EQTransformer의 Transformer block을 얇게 설계하고 ~~다운샘플링을 옵션으로 추가~~하는 등 구조를 변형하여 인코더를 설계하였다.

5.2. UMIS

각각의 인코더에서 추출된 서로 다른 특징 벡터를 공통 표현 공간인 UMIS에 투영한다. UMIS에서는 먼저, 서로 다른 차원의 벡터를 공통된 128차원으로 매핑한다. 그 후 Type Embedding을 통해 모달리티 식별력을 강화한다. 마지막으로 결합된 256차원의 벡터를 다시 128차원으로 압축한다. 이를 통해 서로 다른 데이터 간의 상호작용을 학습하고, 통합된 표현을 생성한다.

5.3. 후처리

UMIS로 통합된 특징을 디코더에 입력해 회귀 분석으로 PGV 값을 추정한다. 이후에는 Vs30 데이터를 활용하여 지역별 기반 특성을 반영해 현실적인 지반 운동 정보를 생성한다. 각 관측소별 PGV 추정 값을 격자 단위로 확장하기 위해, 크리깅 기법을 활용하여 미계측 지역의 PGV 값을 추정하고, 이를 시각화하여 ShakeMap 형태의 지진 위험도 지도를 생성한다.

III. Project-Design

1. 요구사항 정의

본 연구는 지진 연구가 가지는 고유한 복잡성과 관측 데이터의 물리적 한계를 해소하고, 기존의 단일 모달리티 관측 및 물리 수식 의존적 방식이 직면한 비선형적 패턴 분석의 한계와 관측 공백 문제를 극복하는 것을 최우선 요구사항으로 정의한다. 이를 위해 본 프로젝트에서 제안하는 Solution은 지진파형(Seismic Wave) 데이터의 고주파 진동 특성과 GNSS(Global Navigation Satellite System) 데이터의 저주파 지반 변위 데이터를 통합 학습하는 UMIS(Universal Modality-Independent Space) 기반 멀티모달 딥러닝 아키텍처이다.

이 Solution은 단순히 지진파형과 GNSS 데이터를 결합하는 수준을 넘어, 서로 다른 물리적 특징을 가진 지진파형과 GNSS 데이터를 공통된 잠재 공간으로 투영하여 모달리티 간의 상호 보완적인 정보를 추출하도록 설계되었다. 특히 지진파형과 GNSS의 물리적 상관관계를 학습하여 PGV(최대 지반 속도) 추정치에 대한 상호 피드백을 수행함으로써 결과의 신뢰도를 확보한다. 또한 추정된 PGV에 지역별 지반 특성인 Vs30 데이터를 연계하여 증폭 계수를 반영하고, 크리깅(Kriging) 공간 보간을 적용하여 관측소가 없는 미계측 지역의 위험도까지 정밀하게 추정하는 통합 파이프라인을 구축한다.

위와 같은 기술적 요구사항을 충족하고 연구의 객관성을 확보하기 위해, 본 연구는 2011년 일본 도호쿠 대지진과 2024년 일본 노토 대지진 데이터를 활용한 교차 검증(Cross-validation) 프레임워크 내에서 다음과 같은 세부 기능별 실험과 검증을 수행한다.

1.1. 입력 최적화를 위한 전처리 파라미터 비교 실험

이기종 데이터 간의 시공간적 정합성을 확보하기 위해 윈도우 사이즈(Window Size) 변화에 따른 예측 정밀도를 분석한다. 또한 지진파형의 고주파 성분을 효율적으로 학습하기 위한 다운샘플링(Down-sampling)과 GNSS의 낮은 해상도를 보완하기 위한 업샘플링(Up-sampling) 전략을 대조 실험한다. 이를 통해 데이터 유실을 최소화하면서도 높은 정확도로 PGV 값을 추정할 수 있는 최적의 Sampling Rate를 정의하며, 입력 데이터의 윈도우 사이즈가 모델의 학습에 미치는 영향을 정량적으로 입증한다.

1.2. 멀티모달 대 단일 모달리티 성능 비교 실험

제안한 UMIS 기반 멀티모달 모델과 기존의 지진파형 단독 또는 GNSS 단독 모델 간의 성능 차이를 비교 검증한다. RMSE 지표 기준 단독 모델 대비 멀티모달 모델의 40% 이상 오차 감소율 달성을 목표로 한다. 이는 단일 모달리티 모델이 반영하지 못하는 지진의 복잡한 패턴을 본 연구의 멀티모달 딥러닝이 성공적으로 학습했음을 증명한다.

1.3. 지반 보정 및 공간 보간 유효성 검증 실험

PGV 예측값에 지역별 지반 특성 Vs30을 반영한 후처리 모듈의 유효성을 평가한다. 관측소 위치를 기반으로 생성된 점 데이터를 크리깅 기법으로 보간하여 생성된 공간 연속적 ShakeMap을 실제 관측망 데이터와 비교 분석한다. 특히 미계측 지역에서도 실제 지반 증폭 현상이 유효하게 재현되는지 검증함으로써, 제안 시스템이 생성한 지진 위험도 지도가 실제 피해 지

역의 공간적 분포와 높은 상관관계를 가짐을 확인하고 지진 대응 시스템으로서의 실무적 활용 가능성을 제시한다.

2. 전체 시스템 구성

2.1 데이터

본 연구에서는 각 지진의 본진(mainshock) 시점을 중심으로 수집한 지진파형 데이터와 1-Hz GNSS 데이터를 함께 사용하였다. 1-Hz GNSS 데이터는 다양한 공개 데이터베이스 및 기관으로부터 수집된 자료를 기반으로 구축하였다. 구체적으로, 2011년 도호쿠 지진에 대한 GNSS 데이터는 PANGAEA에서 제공하는 GEONET 관측소의 1-Hz PPP 변위 시계열 데이터 중, 도호쿠 지역에 위치한 관측소를 선별하여 활용하였다. 2024년 노토 반도 지진 GNSS 데이터는 일본 국토지리원(Geospatial Information Authority of Japan, GSI)에서 제공하는 GEONET 관측소의 1-Hz PPP 위치 시계열 데이터 중, 진앙으로부터 250km 반경 내에 포함되는 관측소를 선별하여 사용하였다. 지진파형 데이터는 일본 방재과학기술연구소(NIED, National Research Institute for Earth Science and Disaster Resilience)에서 운영하는 Hi-net으로부터 수집하였다. 지진파형 데이터는 앞서 정의한 지진별 지역 기준에 따라 관측소를 선별하여 활용하였다. 라벨은 USGS ShakeMap에서 제공하는 Station List 데이터로부터 PGV를 수집하였다. PGV는 지진 발생 시 지반의 최대 속도를 의미하며, 지반 진동의 강도를 나타내는 대표적인 지표이다. 후처리 단계에서 지반 증폭 효과를 반영하기 위해, 일본 방재과학기술연구소(NIED)의 J-SHIS에서 제공하는 지반 증폭 계수 데이터를 활용하였다. 지반 증폭 계수는 지반의 물리적 특성과 지하 구조를 반영하여 지진파의 증폭 정도를 나타내는 지표이다.


2.2 전처리

2011년 도호쿠 GNSS 데이터는 별도의 가공 없이 그대로 사용하였다. 2024년 노토 반도 지진 GNSS 데이터는 ECEF 좌표계에서 ENU 좌표계로 변환하였으며, 본진 이전 구간의 평균 ECEF 좌표를 기준점으로 설정하여 상대 변위를 계산하였다.

지진파형 데이터는 Hi-net에서 제공된 원시 자료를 활용하여 전처리하였으며, ObsPy를 이용해 관측소별로 시간 순서에 따라 병합하였다. 이후 PGV 라벨이 존재하는 관측소를 대상으로 관측소명을 매칭하고, 각 관측소에 대해 E, N, Z(U) 3성분 파형을 추출하였다.

데이터셋 간 일관된 입력 구성을 위해, 모든 시계열 데이터는 본진 발생 시각을 기준으로 전후 45분 구간으로 제한하였다. 이후 지진파형과 GNSS 데이터에 대해 각각 Z-score 정규화를 수행하였으며, 고정 길이 입력 구성을 위해 윈도우 크기 360초, stride 180초를 적용하여 시계열을 분할하였다. 윈도우 크기 360초, stride 180초는 윈도우 사이즈 비교 실험을 통해 결정된 최적값이다. 또한, 멀티모달 모델 학습을 위해 반경 25km 내에 있는 지진파형 관측소와 GNSS 관측소를 하나의 학습 샘플로 구성하였다. 반경 25km는 지진파형-GNSS 관측소 매칭 반경에 대한 비교 실험을 통해 결정된 최적값이다. 지진파형 데이터는 100Hz, GNSS 데이터는 1Hz의 서로 다른 sampling rate를 유지한 채 각각 별도의 인코더에 입력되도록 설계하였다. 이를 통해 각 모달리티의 고유한 시간적 특성을 보존하면서 통합 학습이 가능하도록 하였다.

2.4.3 전체 아키텍처



전체 시스템은 지진파형과 GNSS 데이터를 각각 개별 인코더에서 처리한 뒤, 이를 UMIS Layer에서 통합한다. 통합된 특징은 디코더를 거쳐 PGV 값을 추정하며, 이후 지반 특성 반영, 공간 보간, 시각화의 후처리를 거쳐 지진 위험 지도를 생성한다.

전체 시스템은 지진 발생 시 수집되는 지진파형 데이터와 1-Hz GNSS 데이터를 동시에 활용하여 PGV(Peak Ground Velocity)를 추정하고, 이를 기반으로 ShakeMap 형태의 지진 위험 지도를 생성하도록 설계하였다. 지진파형 데이터는 100Hz 기반의 시계열 데이터로 지진 발생 직후의 고주파 진동 특성을 효과적으로 반영하며, GNSS 데이터는 1Hz 기반의 저주파 지반 변위 정보를 포함하여 실제 지반의 절대 변형량을 반영할 수 있다. 본 시스템은 이러한 서로 다른 시간적 특성을 가지는 두 모달리티를 효과적으로 활용하기 위해 dual-stream architecture 기반으로 구성하였다.

입력된 지진파형 데이터와 GNSS 데이터는 각각 독립적인 인코더에 입력된다. Seismic Encoder는 지진파형 데이터로부터 급격한 진폭 변화와 시간적 패턴을 학습하며, GNSS Encoder는 저주파 기반의 장기 지반 변위 특성을 추출한다. 이때 지진파형 데이터는 100Hz sampling rate를 유지한 채 입력되고, GNSS 데이터 역시 1Hz sampling rate를 유지하여 각 모달리티의 고유한 물리적 특성이 손실되지 않도록 설계하였다.


각 인코더에서 추출된 feature는 UMIS(Universal Modality-Independent Space) Layer에서 공통 표현 공간으로 투영된 후 통합된다. UMIS Layer에서는 서로 다른 모달리티 간의 feature interaction을 학습하기 위해 cross-modal attention 기반 융합을 수행하며, 이를 통해 지진파형의 고주파 특징과 GNSS의 저주파 변위 특징을 동시에 반영할 수 있도록 하였다.

통합된 feature는 Decoder에 입력되어 최종 PGV 값을 회귀 방식으로 예측한다. 이후 예측된 PGV 값에는 Vs30 기반 지반 증폭 계수를 적용하여 지역별 지반 특성에 따른 증폭 효과를 반영한다. 보정된 PGV 값은 Ordinary Kriging 기반 공간 보간 기법을 통해 미관측 지역까지 확장되며, 최종적으로 격자 형태의 지반 운동 분포를 생성하여 ShakeMap 형태의 지진 위험 지도로 시각화한다.

2.2.4 모듈별 상세 설계

(1) Seismic Encoder

딥러닝 기반 지진파형 아키텍처인 EQTransformer 구조를 차용하였다. 지진파형의 고주파 진동 특성을 다단계로 분석하는 데 최적화되어 있다. 본 연구에서는 지진파형 데이터의 고주




파 기반 시계열 특성을 효과적으로 학습하기 위해 EQTransformer(EQT) 기반 구조를 사용하였다. EQTransformer는 지진 탐지 및 phase picking 분야에서 높은 성능을 보이며 지진학 연구에서 널리 활용되고 있는 딥러닝 기반 아키텍처이다. 특히 CNN 기반 지역 특징 추출과 Transformer 기반 장기 의존성 학습을 동시에 수행할 수 있어 복잡한 지진파형 분석에 적합하다. 본 연구에서는 원본 EQTransformer 구조를 차용하여, PGV 회귀 문제에 적합하도록 layer 깊이와 pooling 구조를 일부 수정하였다.

- 다단계 특징 추출: 7단계의 합성곱(Conv 1D) 계층과 3단계의 MaxPooling을 결합하여 시계열 해상도를 단계적으로 압축하고, 필터수를 8에서 96까지 확장하여 저수준부터 고수준까지의 특징을 추출한다. 초기 3개 계층에서는 MaxPooling을 각 1/2씩 적용하여 시계열 길이를 단계적으로 1/8로 압축시키고, 이후 평균 풀링(avg pooling)을 추가로 수행하여 장시간 지진파형의 feature를 효율적으로 1/32 비율로 압축

하였다.

- 심층 잔차 학습: 75개의 ResNet 블록을 배치하여 깊은 신경망 구조에서도 정보 유실 없이 지진 파형의 비선형적 패턴을 심층적으로 학습한다. 또한 residual connection을 통해 깊은 계층에서도 feature 정보를 안정적으로 전달할 수 있도록 설계하였다.
- 시공간 맥락 파악: 32단계의 Bi-LSTM/NiN 블록과 2단계의 Transformer-Global Attention을 통해 지진 이벤트의 지역적 맥락과 전역적 중요 시점을 동시에 포착한다. Bi-LSTM은 시계열의 전후 문맥 정보를 반영하며, NiN 구조는 feature 차원을 효율적으로 압축한다. 또한 Transformer 구조를 통해 장기 시계열 구간에서 중요한 진동 패턴을 효과적으로 학습할 수 있도록 하였다.

(2) GNSS Encoder



지반의 절대적 이동량과 저주파 변위 특성을 정밀하게 분석하기 위한 인코더를 설계하였다. GNSS 데이터는 1-Hz로 sampling rate가 낮고 변화가 완만한 특성을 가지므로, 급격한 고주파 진동보다는 장기적인 지반 변위와 시간적 연속성을 안정적으로 반영할 수 있도록 구조를 구성하였다.


- 물리적 정보 보존: 합성곱 계층과 ResNet 블록을 통해 지반의 영구 변위 및 정적 오프셋 정보를 정교하게 추출한다. 초기 합성곱(Conv1D) 계층을 통해 GNSS 시계열의 기본 변위

패턴을 추출하고, 3개의 ResNet 블록을 적용하여 지반의 영구 변위 및 정적 오프셋 정보를 정교하게 학습한다. 또한 residual connection 기반 구조를 통해 깊은 계층에서도 fea

ture 정보를 안정적으로 전달할 수 있도록 설계하였다.

- 시계열 안정성 확보: Bi-LSTM과 Transformer 블록을 연계하여 Sampling rate가 낮은 GNSS 데이터 내에서 지반 변화의 전후 맥락을 파악하고 전역적 상관관계를 학습한다. Bi-LSTM은 시간 흐름에 따른 지반 변위의 연속성을 반영하며, Multi-head Attention 기반 Transformer는 장시간 시계열 구간에서 중요한 변위 패턴을 효과적으로 강조한다.


(3) UMIS Layer



서로 다른 특징 벡터를 동일 차원의 잠재 공간으로 투영하여 모달리티 간의 결합을 수행한다. 본 연구에서는 지진파형과 GNSS 데이터의 서로 다른 시간 해상도와 feature distribution을 효과적으로 통합하기 위해 Cross-modal Attention 기반 UMIS 구조를 설계하였다.

- 비선형 공간 투영: GELU 활성화 함수 기반의 MLP를 통해, 지진파형과 GNSS 특징을 공통된 128차원의 UMIS 공간으로 매핑한다. 이를 통해 서로 다른 모달리티의 feature scale 차이를 완화하고 공통 표현 공간에서 상호작용이 가능하도록 하였다.
- 모달리티 식별력 강화: Type Embedding을 각 특징에 더하여, 모델이 데이터의 출처(Seismic/GNSS)를 인지하고 상호 보완적인 가중치를 스스로 조절하게 한다. 이를 통해 모달리티별 특성을 유지하면서도 상호 보완적인 feature weighting이 가능하도록 설계하였다.
- Cross-modal Attention 기반 상호작용: Cross-modal Attention 구조를 적용하여 지진파형 feature가 GNSS 정보를 참조하고, 동시에 GNSS feature 역시 지진파형 정보를 참조하도록 구성하였다. 이를 통해 서로 다른 모달리티 간의 장기 의존성과 상호 보완적 특징을 효과적으로 학습할 수 있도록 하였다. 또한 서로 다른 sequence length를 유지한 상태에서도 feature interaction이 가능하도록 설계하였다.
- 융합 믹싱: 결합된 256차원의 벡터를 Fusion Mixer를 통해 다시 128차원으로 압축하며 두 모달리티 간의 깊은 상호작용을 학습한다. Cross-attention으로 얻은 지진파형 결과는 Sigmoid 기반 gate를 통해 반영량을 동적으로 조절하여 융합된다. GNSS 결과는 mean pooling으로 지진파형과 동일한 길이로 맞추는 후 concatenate한다. 최종적으로 Fusion Mixer를 통해 128차원으로 압축하여 통합된 UMIS Feature를 생성한다.

(4) Decoder




융합된 멀티모달 특징으로부터 최종적인 물리량인 PGV(최대지반속도)를 추정한다.

- Attention Pooling: 시계열 특징 중 지진 위험도 판단에 결정적인 구간에 높은 가중치를 부여하여 하나의 컨텍스트 벡터로 요약한다. Attention score에 Softmax를 적용하여 시간 축에 대한 가중치를 계산하며, 이를 통해 PGV 추정에 중요한 진동 구간의 특징을 효과적으로 강조할 수 있도록 하였다.
- 회귀 분석: MLP 계층을 거쳐 정제된 특징을 바탕으로 최종적

인 PGV값을 정량적으로 산출한다. 이때 Layer Normalization과 Dropout을 적용하여 feature distribution을 안정화하고 과적합을 완화하도록 설계하였다.

(5) 후처리



PGV 추정 값을 미계측 지역까지 확장하고, 지질학적 특징을 반영해 시각화한다.

- 지반 증폭 보정: 지역별 Vs30 데이터를 연계하여 지반 특성에 따른 지진 증폭 효과를 PGV 추정값에 반영한다. 본 연구에서는 J-SHIS 기반 AVS/ARV 데이터를 사용하였으며, ARV(Average Relative Velocity)가 존재하는 경우 이를 직접 증폭 계수로 적용하였다. ARV 정보가 없는 경우에는 Vs30 기반 경험식을 활용하여 증폭 계수를 계산하고, 결측 관측소에는 중앙값 기반 fallback 보정을 적용하여 안정성을 확보하였다.
- 크리깅 기반 공간 보간: Ordinary Kriging **크리깅(Kriging)** 기법을 적용하여 미계측 지역까지 PGV 값을 확장해 연속적인 위험도

분포를 생성한다. Variogram model은 spherical model을 사용하였으며, 0.02° 해상도의 공간 격자를 생성하여 보간을 수행하였다. 또한 크리깅 과정에서 공간 분산(kriging variance)을 함께 계산하여 보간 결과의 불확실성을 추정할 수 있도록 하였다.

- ShakeMap 시각화: 생성한 위험도 분포를 2차원 ShakeMap 형태로 구현하여 지진 위험도를 시각화한다. 시각화 과정에서는 USGS ShakeMap 기준의 PGV 구간 및 색상 체계를 적용하였으며, 로그 스케일(LogNorm) 기반 컬러맵을 사용하여 낮은 PGV와 높은 PGV 영역을 동시에 효과적으로 표현할 수 있도록 하였다. 또한 contour line을 함께 표시하여 지역별 지반 운동 강도의 변화를 직관적으로 확인할 수 있도록 구성하였다.

3. 과제의 산출물

본 연구는 다음의 세 가지 핵심 산출물을 도출한다.

3.1. UMIS 기반 멀티모달 딥러닝 아키텍처

지진파형과 GNSS 라는 서로 다른 모달리티의 데이터를 통합 처리하기 위한 독자적인 딥러닝 모델 아키텍처를 구축한다.

- Dual-Stream Encoder: 고주파 진동(지진파형)과 저주파 변위(GNSS)의 물리적 특성을 각각 독립적으로 보존하며 학습하는 고성능 인코더
- UMIS(Universal Modality-Independent Space): 서로 다른 물리량을 공통 잠재 공간으로 투영하고, 모달리티 임베딩을 통해 데이터 간의 화학적 융합을 수행

3.2. 딥러닝 기반 ShakeMap 시각화

점 단위의 PGV 추정값을 면 단위의 지도로 확장하여, 딥러닝 기반의 지진 위험도 지도를 시각화한 결과물을 생성한다.

- 통합 분석 파이프라인: 'PGV 추정 → Vs30 기반 지반 보정 → 크리깅 공간 보간'의 후처

리 시스템 구축

- 지리적 현실성 반영: 지역별 지반 특성을 연계함으로써, 미계측 지역에서도 실제 지반 증폭 현상이 반영된 신뢰도 높은 위험도 지도를 구현

3.3 멀티모달 성능 검증 및 단일모달과의 비교 분석

단일 모달리티 대비 멀티모달 접근법의 우수성을 실험적으로 증명한 분석 결과물을 생성한다.

- 정량적 성능 향상 및 객관적 타당성 확보: 단일 모달리티 모델 대비 RMSE 기준 약 40%의 오차 감소를 달성으로, 멀티모달 모델의 타당성 확보

4. 실험

4.1 방법

항목	설정값
Optimizer	AdamW
Learning rate	3e-4
LR Scheduler	Warmup (5 epoch)+ Cosine Annealing (min 5%)
Batch size	16
Epoch	100
Checkpoint (patience 40)	Best validation model
Loss function	HuberMSELoss (Huber loss 0.5+ MSE loss 0.5)
Random seed	42

모델 파라미터 설정값은 위의 표와 같다. 학습은 PyTorch 프레임워크 기반으로 구현하였으며, GPU 환경에서 효율적인 딥러닝 학습 및 다양한 시계열 모델 구조 구현이 용이하다는 점을 고려하여 선택하였다. 최적화 알고리즘으로는 AdamW optimizer를 사용하였다. AdamW는 adaptive learning rate 기반의 Adam optimizer에서 weight decay를 분리하여 적용함으로써 과적합을 완화하고 일반화 성능을 향상시키는 장점이 있어 시계열 딥러닝 모델 학습에 적합하다고 판단하였다. 초기 learning rate는 3e-4로 설정하였으며, 이는 학습 안정성과 수렴 속도를 모두 고려한 값이다. 너무 큰 learning rate는 학습 초기에 불안정한 gradient update를 유발할 수 있고, 너무 작은 값은 수렴 속도를 저하시킬 수 있기 때문에 여러 선행 실험을 통해 해당 값을 선택하였다.

학습률 스케줄링에는 warmup과 cosine annealing을 결합한 방식을 사용하였다. 학습 초기 5 epoch 동안 warmup을 적용하여 learning rate를 점진적으로 증가시킴으로써 초기 gradient instability를 완화하고 안정적인 feature learning이 가능하도록 하였다. 이후 cosine annealing scheduler를 적용하여 learning rate를 점진적으로 감소시켰으며, 최소 learning rate는 초기 learning rate의 5%로 설정하였다. 이는 학습 후반부에서 과도한 parameter u

pdate를 방지하고 보다 안정적인 수렴을 유도하기 위함이다.

Batch size는 16으로 설정하였다. 본 연구에서 사용한 입력 데이터는 장시간 시계열 데이터로 구성되어 있어 메모리 사용량이 크기 때문에 GPU 메모리 한계를 고려할 필요가 있었다. 또한 너무 작은 batch size는 gradient variance를 증가시켜 학습 안정성을 저하시킬 수 있으므로, 메모리 효율성과 gradient stability를 함께 고려하여 16을 사용하였다. Epoch 수는 100으로 설정하였으며, 충분한 학습 기회를 제공하면서도 과적합을 방지하기 위해 patience 40에 validation loss 기반 checkpoint를 함께 사용하였다.

손실 함수로는 MSE와 Huber loss를 결합한 hybrid loss를 사용하였다. MSE는 큰 오차에 민감하게 반응하기 때문에 높은 PGV 영역에서의 오차 학습에 효과적이지만, 이상치(outlier)에 의해 학습이 불안정해질 수 있다는 한계가 있다. 반면 Huber loss는 작은 오차 구간에서는 MSE처럼 동작하면서도 큰 오차 구간에서는 gradient 증가를 완화하여 이상치에 대한 민감도를 줄이는 특성을 가진다. 따라서 두 손실 함수를 5:5 비율로 결합하여 높은 PGV 영역에 대한 학습 성능과 전체 학습 안정성을 동시에 확보하고자 하였다. 마지막으로 random seed는 42로 고정하여 데이터 분할 및 모델 초기화 과정에서의 재현성(reproducibility)을 확보하였다.

4.2 결과


본 연구에서는 일본의 2011년 도호쿠 지진과 2024년 노토 지진 데이터를 활용하여 cross-event 기반 평가를 수행하였다. 이는 하나의 지진 이벤트로 학습한 모델을 학습되지 않은 이벤트에 적용하는 실제 상황을 모사하기 위함이며, 도호쿠 데이터로 학습하고 노토 데이터로 테스트하는 실험과 역방향 실험을 각각 수행하였다.

Seismic-only 모델 및 GNSS-only 모델을 베이스라인으로 설정하여 멀티모달 모델과의 성능을 비교하였으며, cross-event 이벤트 간 데이터 분포 차이로 인한 성능 저하를 완화하기 위해 target 이벤트 데이터의 일부를 Validation set으로 활용하였다. Test set과 Validation set은 각각 80%와 20% 비율로 구성하였으며, 성능 평가 지표로는 원래 스케일로 복원된 값에 대한 RMSE를 사용하였다.

실험별 성능 지표 \ 모델	Seismic-only	GNSS-only	Proposed
도호쿠 학습 실험 Test Loss	1.9782	2.1320	1.6843
도호쿠 학습 실험 Test RMSE	12.11	13.12	9.88
노토 학습 실험 Test Loss	0.8792	0.4909	0.2881
노토 학습 실험 Test RMSE	17.69	17.23	11.47

실험 환경별 각 모델의 PGV 예측 RMSE를 위의 표에 나타내었다. 도호쿠 학습 실험에서 제안 모델의 RMSE는 9.88로 나타났으며, Seismic-only 및 GNSS-only 대비 각각 18.4%, 24.7% 감소하였다. 노토 학습 실험에서는 제안 모델의 RMSE가 11.47이며, Seismic-only 및 GNSS-only 대비 각각 35.2%, 33.4% 감소하였다.

아래 그림은 예측된 PGV 값에 지반 증폭 계수 보정, Kriging 공간 보간을 순차적으로 적용하여 ShakeMap을 생성한 것이다. 좌측은 도호쿠 학습 실험, 우측은 노토 학습 실험의 ShakeMap이다.



5. 결론

본 연구에서는 지진파형과 1-Hz GNSS 데이터를 통합하는 멀티모달 딥러닝 기반 PGV 예측 모델을 제안하였다. 제안 모델은 지진파형 인코더와 GNSS 인코더를 통해 각 모달리티의 feature를 독립적으로 추출하고, UMIS layer의 cross-attention 융합을 통해 이중 모달리티 간 상호작용을 학습하였다. cross-event 기반 실험에서 제안 모델은 단일모달 베이스라인 대비 RMSE가 감소하였으며, 지반 증폭 계수 보정 및 크리깅 기반 후처리를 통해 격자 기반 ShakeMap을 생성하였다.

그러나 본 연구는 도호쿠 및 노토 두 지진 이벤트만을 활용하였으며, 데이터셋 부족 및 두 지진 이벤트 간의 큰 규모 차이로 cross-event 일반화에 제약이 존재한다. 또한 GNSS 관측소의 PGV 레이블 할당 방식으로 인해 레이블 노이즈가 발생할 수 있으며, 이는 학습 효율을 저하시키는 요인으로 작용할 수 있다. 그럼에도 불구하고 두 실험 모두에서 제안 모델은 단일모달 베이스라인 대비 낮은 RMSE를 나타내어, 멀티모달 융합의 유효성을 확인하였다. 현재 예측 RMSE 값으로 보아 실사용 적용에 한계가 있으나, 향후 연구에서는 다양한 규모의 지진 이벤트 데이터를 추가 확보함으로써 모델의 일반화 성능을 개선할 계획이다.