26

# 프로젝트 1차 보고서

멀티모달 딥러닝 기반 지진 PGV 추정 및 위험지도 시각화
(Multimodal Deep Learning-Based PGV Estimation and Earthquake Hazard Mapping)


연구트랙 26팀 TriAI
지도교수 이형준

2371062 조혜림 · 2371012 김민 · 2371031 박소영

# 목차

Ⅰ Team Info ····· 3
1. 과제명 ····· 3
2. 팀 정보 ····· 3
3. 팀 구성원 ····· 3

Ⅱ Project-Summary ····· 4
1. 문제 정의 ····· 4
2. 기존 연구와의 비교 ····· 4
2.1 단일 모달리티 기반 PGV 예측 연구 ····· 4
2.2 멀티모달 딥러닝 기반 이벤트 분류/규모 추정 연구 ····· 5
2.3 기존 연구와의 차이점 ····· 5
3. 제안 내용 ····· 5
4. 기대 효과 및 의의 ····· 6
4.1 고정밀도 PGV 추정 ····· 6
4.2 미계측 지역 보간 및 시각화 ····· 6
4.3 멀티모달 딥러닝 기반 PGV 추정 아키텍처 제안 ····· 6
4.4 지진 대응의 실무 활용성 ····· 6
5. 주요 기능 리스트 ····· 7
5.1 모달리티별 인코더 설계 ····· 7
5.2 UMIS ····· 7
5.3 후처리 ····· 7

Ⅲ Project-Design ····· 8
1. 요구사항 정의 ····· 8
1.1 입력 최적화를 위한 전처리 파라미터 비교 실험 ····· 8
1.2 멀티모달 대 단일모달리티 성능 비교 실험 ····· 8
1.3 지반 보정 및 공간 보간 유효성 검증 ····· 8
2. 전체 시스템 구성 ····· 9
2.2 전체 아키텍처 ····· 9
2.3 모듈별 상세 설계 ····· 9
3. 과제의 산출물 ····· 11
3.1 UMIS 기반 멀티모달 딥러닝 아키텍처 ····· 11
3.2 딥러닝 기반 ShakeMap 시각화 ····· 11
3.3 멀티모달 성능 검증 및 단일모달과의 비교 분석 ····· 11

# Ⅰ. Team Info

**1. 과제명**

멀티모달 딥러닝 기반 지진 PGV 추정 및 위험지도 시각화

Multimodal Deep Learning-Based PGV Estimation and Earthquake Hazard Mapping

**2. 팀 정보**

- 팀 번호: 26
- 팀 이름: TriAI

**3. 팀 구성원**

| 이름 | 학번 | 역할 |
|---|---|---|
| 조혜림 | 2371062 | 리더, 데이터 수집 및 전처리, 서류 메인 관리, 디코더 설계, 멀티모달 모델 설계, 학습 및 검증 |
| 김 민 | 2371012 | 팀원, 데이터 수집 및 전처리, 깃허브 메인 관리, 지진파형 모델 설계, 학습 및 검증 |
| 박소영 | 2371031 | 팀원, 데이터 수집 및 전처리, 노션 메인 관리, GNSS 모델 설계, 학습 및 검증 |

# Ⅱ. Project-Summary

## 1. 문제 정의

기존의 지진 위험도 분석 방법으로는 ShakeMap과 PSHA가 널리 사용되고 있다. ShakeMap은 지진 발생 이후 지진계에서 관측된 데이터를 기반으로 특정 지역의 지반 흔들림 강도를 지도 형태로 시각화하는 방법으로, 실제 지진 이벤트에 대한 공간적 분포를 직관적으로 파악할 수 있다는 장점이 있다. 그러나 관측 데이터가 존재하지 않는 지역에 대해서는 경험적 지반운동 예측식(GMPE)에 의존하여 값을 보완하기 때문에, 센서 분포가 불균형한 경우 공간적 정확도가 저하될 수 있다. 또한 ShakeMap은 지진 발생 이후에만 생성 가능한 사후 분석 도구로서, 실시간 예측이나 조기 대응 시스템으로 활용하는 데에는 한계가 있다.

PSHA(Probabilistic Seismic Hazard Analysis)는 특정 지역에서 일정 기간 동안 발생할 수 있는 지진으로 인한 지반 흔들림의 크기를 확률적으로 추정하는 방법으로, 장기적인 지진 위험도 평가 및 내진 설계 기준 수립에 활용된다. 하지만 PSHA는 과거 지진 기록과 단층 정보, 그리고 GMPE와 같은 물리·통계 기반 모델에 크게 의존하기 때문에, 실제 지진 발생 시 나타나는 비선형적이고 복잡한 시공간적 패턴을 충분히 반영하기 어렵다. 특히 개별 지진 이벤트에 따른 지역적 특성이나 다양한 관측 데이터 간의 상호작용을 고려하지 못한다는 한계가 존재한다.

딥러닝 기반 지진 분석 연구의 경우에도, 주로 지진파형 데이터와 같은 단일 모달리티에 기반하거나 제한적인 관측 정보를 활용하는 경우가 많아 지반 변형을 나타내는 주요 지표인 PGV를 정밀하게 추정하기 어렵다. 또한 미계측 지역에서의 관측 공백으로 공간적 연속성이 저하되어, 전체적인 위험도 추정의 불확실성을 증가시키는 요인으로 작용한다.

따라서 기존의 물리수식 기반 분석 방식과 딥러닝 기반 분석 연구는 실제 지진의 복잡한 특성을 충분히 반영하지 못하므로, 다양한 관측 데이터를 통합적으로 활용하여 보다 정밀하고 신뢰성 있는 지진 위험도 추정이 필요하다.

본 연구의 목표는 지진파형 데이터와 GNSS 데이터를 통합적으로 활용하는 멀티모달 딥러닝 모델을 통해 지반 변형을 나타내는 주요 지표인 PGV(최대지반속도)를 보다 정밀하게 추정하는 것을 목표로 한다. 또한 다양한 관측 데이터를 통합하여 기존 방법의 한계를 극복하고, 신뢰성 있는 지진 위험도 수치를 추정하고자 한다.

## 2. 기존 연구와의 비교

### 2.1. 단일 모달리티 기반 PGV 예측 연구

- (1) Liu, J., Ma, Q., & Xie, Q. (2025). A Deep Learning Model for On-Site PGV Prediction in Earthquake Early Warning Integrating Prior Knowledge. In Proceedings of the 2025 5th International Conference on Internet of Things and Machine Learning (IoTML '25), 80–84. Association for Computing Machinery. https://doi.org/10.1145/3749566.3749585
- (2) Gao, Z., Li, Y., Shan, X., & Zhu, C. (2021). Earthquake Magnitude Estimation

from High-Rate GNSS Data: A Case Study of the 2021 Mw 7.3 Maduo Earthquake. Remote Sensing, 13(21), 4478. https://doi.org/10.3390/rs13214478

기존의 PGV 예측 연구는 주로 단일 모달리티 데이터를 기반으로 수행되어 왔다. (1)의 연구에서는 지진파형 데이터를 입력으로 활용하여 딥러닝 기반으로 PGV를 예측하는 모델을 제안한다. 이 모델은 지진파형의 시각적 특성을 효과적으로 학습하여 실시간 예측이 가능하다는 장점이 있다. 그러나 지진파형 데이터만을 활용하기 때문에 실제 지표 변형을 직접적으로 반영하지 못하며, 단일 센서 기반 입력으로 인해 정보가 제한된다는 한계가 존재한다.

(2)의 연구에서는 고속 GNSS 데이터를 활용하여 지진 규모를 추정하는 방법을 제안하였다. 이 방법은 GNSS 데이터를 통해 지반의 실제 변위를 직접 반영할 수 있다는 장점이 있으며, 특히 대규모 지진에서 신뢰도 높은 정보를 제공할 수 있다. 그러나 GNSS 데이터는 샘플링 속도가 상대적으로 낮아 고주파 성분을 충분히 반영하지 못하며, 노이즈에 민감하여 단독으로는 정밀한 PGV 추정에 한계가 존재한다.

### 2.2. 멀티모달 딥러닝 기반 이벤트 분류/규모 추정 연구

- Zhu, J., Li, S. & Song, J. Multimodal deep learning network for fast seismic discrimination and magnitude classification. Geosci. Lett. 12, 39 (2025). https://doi.org/10.1186/s40562-025-00412-7.

최근에는 서로 다른 데이터 소스를 결합하여 활용하려는 멀티모달 접근이 일부 연구에서 시도되고 있다. 해당 연구에서는 다양한 입력 데이터를 활용한 딥러닝 모델을 제안했다. 이 모델은 서로 다른 데이터 간의 보완적인 정보를 활용할 수 있다는 장점이 있지만, 이벤트 분류나 규모 추정 중심이며 PGV와 같은 연속적인 지반 운동 값을 직접 예측하는 데에는 적용되지 않았다. 또한 대부분의 기존 멀티모달 연구는 데이터를 단순히 결합하는 수준에 머물러 있어, 모달리티 간의 상호작용을 효과적으로 학습하지 못한다는 한계가 있다.

### 2.3. 기존 연구와의 차별점

따라서 기존 연구들은 단일 모달리티에 의존하거나, 멀티모달 데이터를 활용하더라도 통합 방식이 제한적이고 실제 지반 변형을 정밀하게 반영하는 PGV 예측에는 여전히 한계가 존재한다. 이에 본 연구에서는 지진파형 데이터와 GNSS 데이터를 통합적으로 활용하고, 이를 공통 표현 공간으로 투영하여 학습하는 멀티모달 딥러닝 모델을 제안함으로써, 기존 연구의 한계를 극복하고 보다 정밀한 PGV 예측을 수행하고자 한다.

## 3. 제안 내용

기존 지진 위험도 분석 방법이 가지는 단일 모달리티 의존, 멀티모달 데이터의 상호작용 미반영 등으로 인한 PGV 정밀 추정의 한계를 해결하기 위해 본 연구에서는 지진파형 데이터와 GNSS 데이터를 통합적으로 활용하는 멀티모달 딥러닝 기반 PGV 예측 모델을 제안한다.

지진파형와 GNSS에 대한 전용 인코더를 사용해, 각 모달리티의 독립적인 특성을 효과적으로 추출한다. 이후 서로 다른 모달리티에서 추출된 특징을 UMIS((Universal Modality-Indep

endent Space)로 투영하여, 시공간적인 결합과 두 모달리티의 깊은 상호작용을 학습한다.

통합된 표현을 디코더에 입력해 회귀분석으로 PGV를 추정하여, 단일 모달리티 기반 접근보다 정밀한 지반 운동 추정을 가능하게 한다. 특히 본 모델은 지진파형의 시간적 특성과 GNSS의 실제 변위 정보를 동시에 반영함으로써, 기존 방법의 한계를 보완하고 신뢰성 높은 PGV 추정을 수행할 수 있도록 설계하였다.

또한 추정된 PGV를 기반으로 후처리(post-processing) 작업를 수행한다. 먼저, Vs30 지반 데이터와의 연계를 통해 지역별 지반 특성을 반영하여 현실적인 지반 운동 정보를 생성한다. 또한 센서가 설치되지 않은 지역에 대해서는 크리깅(kriging) 기법을 활용하여 공간적 보간을 수행함으로써 관측 공백을 보완한다. 마지막으로, 이러한 과정을 통해 생성된 PGV 분포를 ShakeMap 형태로 시각화하여 지진 위험도를 직관적으로 표현할 수 있도록 한다.

마지막으로, 본 연구에서는 제안한 멀티모달 모델의 성능을 검증하기 위해, 동일한 데이터셋을 기반으로 지진파형 및 GNSS 단일 모달리티 모델과의 비교 실험을 수행한다. 이를 통해 멀티모달 접근의 효과와 성능 향상을 정량적으로 분석한다.

## 4. 기대 효과 및 의의

### 4.1. 고정밀도 PGV 추정

멀티모달 딥러닝 모델을 기반으로 PGV를 추정하여, 기존 단일 모달리티 모델보다 복잡한 지진 패턴을 파악하여 관측소별 PGV 값을 추정한다. 또한 Vs30 지반 데이터를 연계를 통한 지반 증폭 지수를 반영으로, 정확하고 정밀한 PGV 값을 추정해 지진 위험도 평가의 신뢰성을 향상시킨다.

### 4.2. 미계측 지역 보간 및 시각화

크리깅(Kriging) 기반 공간 보간을 통해, 미계측 지역까지 포함한 연속적인 PGV 분포를 생성한다. 이를 시각화하여 ShapeMap 형태의 지진 위험도 지도를 생성한다. 이는 기존 ShakeMap 기반 방법의 공간적 한계를 보완하고, 현실적인 위험도 시각화를 가능하게 한다.

### 4.3. 멀티모달 딥러닝 기반 PGV 추정 아키텍처 제안

본 연구는 지진파형-GNSS 통합의 새로운 멀티모달 딥러닝 아키텍처를 제안한다. 해당 아키텍처는 UMIS Layer를 포함하여, 지진파형과 GNSS 데이터 간의 상호작용을 효과적으로 학습할 수 있는 새로운 접근 방식을 제시한다는 점에서 학문적 의의를 가진다. 이러한 접근은 향후 다양한 지구물리 데이터 통합 연구로 확장될 수 있는 기반을 제공할 것으로 기대된다.

### 4.4. 지진 대응의 실무 활용성

ShakeMap 형태의 지진 위험도 지도는 실무에 활용될 가능성을 가진다. 지진 조기 경보 시스템(Earthquake Early Warning) 및 재난 대응 시스템에서 보다 신속하고 정확한 의사결정을 지원할 수 있으며, 인프라 안전 관리 및 지진 위험도 분석 분야에서도 활용될 수 있다.

## 5. 주요 기능 리스트

### 5.1. 모달리티별 인코더 설계

지진파형과 GNSS 데이터를 각각 별도의 인코더에 입력하여 특징을 추출한다. 지진파형의 경우 EQTransformer의 구조를 차용하여 인코더를 설계하였다. GNSS의 경우에는 지진파형과 달리 저주파라는 고유한 특성에 맞게 EQTransformer의 Transformer block을 얕게 설계하고 다운샘플링을 옵션으로 추가하는 등 구조를 변형하여 인코더를 설계하였다.

### 5.2. UMIS

각각의 인코더에서 추출된 서로 다른 특징 벡터를 공통 표현 공간인 UMIS에 투영한다. UMIS에서는 먼저, 서로 다른 차원의 벡터를 공통된 128차원으로 매핑한다. 그 후 Type Embedding을 통해 모달리티 식별력을 강화한다. 마지막으로 결합된 256차원의 벡터를 다시 128차원으로 압축한다. 이를 통해 서로 다른 데이터 간의 상호작용을 학습하고, 통합된 표현을 생성한다.

### 5.3. 후처리

UMIS로 통합된 특징을 디코더에 입력해 회귀 분석으로 PGV 값을 추정한다. 이후에는 Vs30 데이터를 활용하여 지역별 기반 특성을 반영해 현실적인 지반 운동 정보를 생성한다. 각 관측소별 PGV 추정 값을 격자 단위로 확장하기 위해, 크리깅 기법을 활용하여 미계측 지역의 PGV 값을 추정하고, 이를 시각화하여 ShakeMap 형태의 지진 위험도 지도를 생성한다.

# Ⅲ. Project-Design

## 1. 요구사항 정의

본 연구는 지진 연구가 가지는 고유한 복잡성과 관측 데이터의 물리적 한계를 해소하고, 기존의 단일 모달리티 관측 및 물리 수식 의존적 방식이 직면한 비선형적 패턴 분석의 한계와 관측 공백 문제를 극복하는 것을 최우선 요구사항으로 정의한다. 이를 위해 본 프로젝트에서 제안하는 Solution은 지진파형(Seismic Wave) 데이터의 고주파 진동 특성과 GNSS(Global Navigation Satellite System) 데이터의 저주파 지반 변위 데이터를 통합 학습하는 UMIS(Universal Modality-Independent Space) 기반 멀티모달 딥러닝 아키텍처이다.

이 Solution은 단순히 지진파형과 GNSS 데이터를 결합하는 수준을 넘어, 서로 다른 물리적 특징을 가진 지진파형과 GNSS 데이터를 공통된 잠재 공간으로 투영하여 모달리티 간의 상호 보완적인 정보를 추출하도록 설계되었다. 특히 지진파형과 GNSS의 물리적 상관관계를 학습하여 PGV(최대 지반 속도) 추정치에 대한 상호 피드백을 수행함으로써 결과의 신뢰도를 확보한다. 또한 추정된 PGV에 지역별 지반 특성인 Vs30 데이터를 연계하여 증폭 계수를 반영하고, 크리깅(Kriging) 공간 보간을 적용하여 관측소가 없는 미계측 지역의 위험도까지 정밀하게 추정하는 통합 파이프라인을 구축한다.

위와 같은 기술적 요구사항을 충족하고 연구의 객관성을 확보하기 위해, 본 연구는 2011년 일본 도호쿠 대지진과 2024년 일본 노토 대지진 데이터를 활용한 교차 검증(Cross-validation) 프레임워크 내에서 다음과 같은 세부 기능별 실험과 검증을 수행한다.

### 1.1. 입력 최적화를 위한 전처리 파라미터 비교 실험

이기종 데이터 간의 시공간적 정합성을 확보하기 위해 윈도우 사이즈(Window Size) 변화에 따른 예측 정밀도를 분석한다. 또한 지진파형의 고주파 성분을 효율적으로 학습하기 위한 다운샘플링(Down-sampling)과 GNSS의 낮은 해상도를 보완하기 위한 업샘플링(Up-sampling) 전략을 대조 실험한다. 이를 통해 데이터 유실을 최소화하면서도 높은 정확도로 PGV 값을 추정할 수 있는 최적의 Sampling Rate를 정의하며, 입력 데이터의 윈도우 사이즈가 모델의 학습에 미치는 영향을 정량적으로 입증한다.

### 1.2. 멀티모달 대 단일 모달리티 성능 비교 실험

제안한 UMIS 기반 멀티모달 모델과 기존의 지진파형 단독 또는 GNSS 단독 모델 간의 성능 차이를 비교 검증한다. RMSE 지표 기준 단독 모델 대비 멀티모달 모델의 40% 이상 오차 감소율 달성을 목표로 한다. 이는 단일 모달리티 모델이 반영하지 못하는 지진의 복잡한 패턴을 본 연구의 멀티모달 딥러닝이 성공적으로 학습했음을 증명한다.

### 1.3. 지반 보정 및 공간 보간 유효성 검증 실험

PGV 예측값에 지역별 지반 특성 Vs30을 반영한 후처리 모듈의 유효성을 평가한다. 관측소 위치를 기반으로 생성된 점 데이터를 크리깅 기법으로 보간하여 생성된 공간 연속적 ShakeMap을 실제 관측망 데이터와 비교 분석한다. 특히 미계측 지역에서도 실제 지반 증폭 현상이 유효하게 재현되는지 검증함으로써, 제안 시스템이 생성한 지진 위험도 지도가 실제 피해 지

역의 공간적 분포와 높은 상관관계를 가짐을 확인하고 지진 대응 시스템으로서의 실무적 활용 가능성을 제시한다.

## 2. 전체 시스템 구성

### 2.1 전체 아키텍처

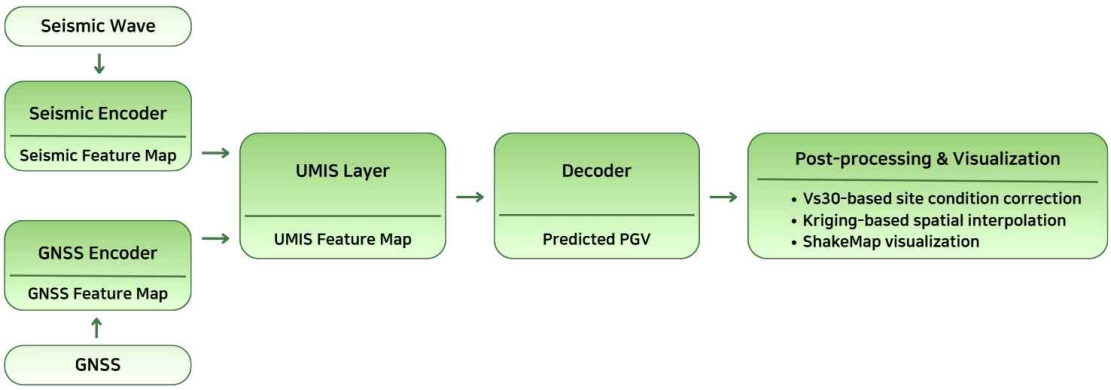


전체 시스템은 지진파형과 GNSS 데이터를 각각 개별 인코더에서 처리한 뒤, 이를 UMIS Layer에서 통합한다. 통합된 특징은 디코더를 거쳐 PGV 값을 추정하며, 이후 지반 특성 반영, 공간 보간, 시각화의 후처리를 거쳐 지진 위험 지도를 생성한다.

### 2.2 모듈별 상세 설계

(1) Seismic Encoder

딥러닝 기반 지진파형 아키텍처인 EQTransformer 구조를 차용하였다. 지진파형의 고주파 진동 특성을 다단계로 분석하는 데 최적화되어 있다.

- 다단계 특징 추출: 7단계의 합성곱(Conv 1D) 계층과 MaxPooling을 결합하여 시계열 해상도를 단계적으로 압축하고, 필터 수를 8에서 96까지 확장하여 저수준부터 고수준까지의 특징을 추출한다.
- 심층 잔차 학습: 7개의 ResNet 블록을 배치하여 깊은 신경망 구조에서도 정보 유실 없이 지진 파형의 비선형적 패턴을 심층적으로 학습한다.
- 시공간 맥락 파악: 3단계의 Bi-LSTM/NiN 블록과 2단계의 Transformer-Global Attention을 통해 지진 이벤트의 지역적 맥락과 전역적 중요 시점을 동시에 포착한다.

(2) GNSS Encoder

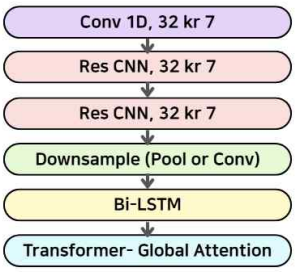


지반의 절대적 이동량과 저주파 변위 특성을 정밀하게 분석하기 위한 인코더를 설계하였다.

- 물리적 정보 보존: 합성곱 계층과 ResNet 블록을 통해 지반의 영구 변위 및 정적 오프셋 정보를 정교하게 추출한다.
- 시계열 안정성 확보: Bi-LSTM과 Transformer 블록을 연계하여 Sampling rate가 낮은 GNSS 데이터 내에서 지반 변화의 전후 맥락을 파악하고 전역적 상관관계를 학습한다.

(3) UMIS Layer

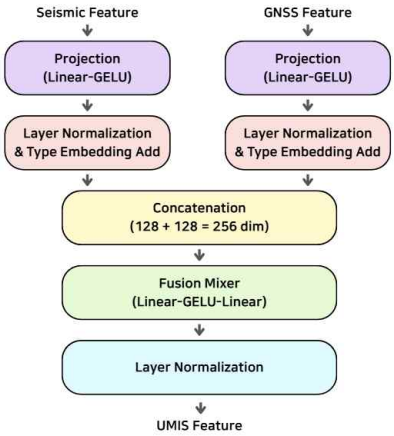


서로 다른 특징 벡터를 동일 차원의 잠재 공간으로 투영하여 모달리티 간의 결합을 수행한다.

- 비선형 공간 투영: GELU 활성화 함수 기반의 MLP를 통해, 지진파형과 GNSS 특징을 공통된 128차원의 UMIS 공간으로 매핑한다.
- 모달리티 식별력 강화: Type Embedding을 각 특징에 더하여, 모델이 데이터의 출처(Seismic/GNSS)를 인지하고 상호 보완적인 가중치를 스스로 조절하게 한다.
- 융합 믹싱: 결합된 256차원의 벡터를 Fusion Mixer를 통해 다시 128차원으로 압축하며 두 모달리티 간의 깊은 상호작용을 학습한다.

(4) Decoder

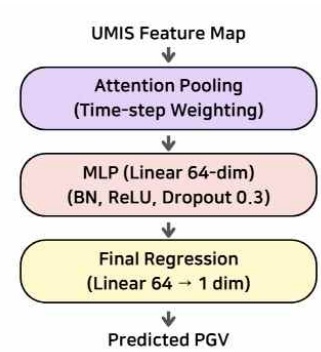


융합된 멀티모달 특징으로부터 최종적인 물리량인 PGV(최대지반속도)를 추정한다.

- Attention Pooling: 시계열 특징 중 지진 위험도 판단에 결정적인 구간에 높은 가중치를 부여하여 하나의 컨텍스트 벡터로 요약한다.
- 회귀 분석: MLP 계층을 거쳐 정제된 특징을 바탕으로 최종적인 PGV값을 정량적으로 산출한다.

(5) 후처리

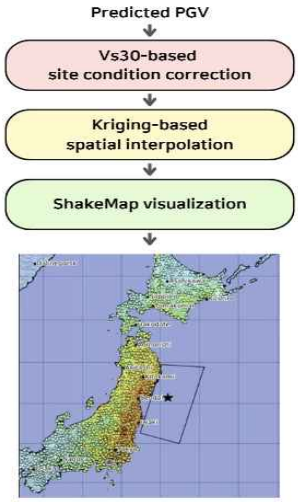


PGV 추정 값들을 미계측 지역까지 확장하고, 지질학적 특징을 반영해 시각화한다.

- 지반 증폭 보정: 지역별 Vs30 데이터를 연계하여 지반 특성에 따른 지진 증폭 효과를 PGV 추정값에 반영한다.
- 크리깅 기반 공간 보간: 크리깅(Kriging) 기법을 적용하여 미계측 지역까지 확장해 연속적인 위험도 분포를 생성한다.
- ShakeMap 시각화: 생성한 위험도 분포를 2차원 ShakeMap 형태로 구현하여 지진 위험도를 시각화한다.

## 3. 과제의 산출물

본 연구는 다음의 세 가지 핵심 산출물을 도출한다.

### 3.1. UMIS 기반 멀티모달 딥러닝 아키텍처

지진파형과 GNSS 라는 서로 다른 모달리티의 데이터를 통합 처리하기 위한 독자적인 딥러닝 모델 아키텍처를 구축한다.

- Dual-Stream Encoder: 고주파 진동(지진파형)과 저주파 변위(GNSS)의 물리적 특성을 각각 독립적으로 보존하며 학습하는 고성능 인코더
- UMIS(Universal Modality-Independent Space): 서로 다른 물리량을 공통 잠재 공간으로 투영하고, 모달리티 임베딩을 통해 데이터 간의 화학적 융합을 수행

### 3.2. 딥러닝 기반 ShakeMap 시각화

점 단위의 PGV 추정값을 면 단위의 지도로 확장하여, 딥러닝 기반의 지진 위험도 지도를 시각화한 결과물을 생성한다.

- 통합 분석 파이프라인: ‘PGV 추정 → Vs30 기반 지반 보정 → 크리깅 공간 보간’의 후처리 시스템 구축
- 지리적 현실성 반영: 지역별 지반 특성을 연계함으로써, 미계측 지역에서도 실제 지반 증폭 현상이 반영된 신뢰도 높은 위험도 지도를 구현

### 3.3 멀티모달 성능 검증 및 단일모달과의 비교 분석

단일 모달리티 대비 멀티모달 접근법의 우수성을 실험적으로 증명한 분석 결과물을 생성한다.

- 정량적 성능 향상 및 객관적 타당성 확보: 단일 모달리티 모델 대비 RMSE 기준 약 40%의 오차 감소율 달성으로, 멀티모달 모델의 타당성 확보