

Multimodal Deep Learning-Based PGV Estimation and Earthquake Hazard Mapping

멀티모달 딥러닝 기반 지진 PGV 추정 및 위험지도 시각화

26팀 TriAI | 조혜림 김민 박소영

연구 배경 및 목표

지진파형, GNSS와 같은
단일 모달리티 데이터에
의존한 기존 연구

- 복잡한 지반 특성 반영의 한계
- 관측소가 없는 지역에서의
공간적 정보 반영 어려움
- 서로 다른 데이터 간의
통합 방식에 대한 연구 부족

- 지진파형과 GNSS 데이터를 **UMIS** 기반으로 통합한
멀티모달 딥러닝 모델을 통해 PGV 추정
- 지반 증폭 계수 반영 및 **미계측 지역 보간**을 통해
지진 진도의 공간적 분포 정밀 추정 및 **위험지도 생성**
- 제안 모델의 성능을 **단일 모달리티 기반 모델**과 비교하여
멀티모달 접근 방식의 효과 검증

데이터 및 전처리

지진파형 NIED의 Hi-net
GNSS PANGAEA, GSI의 GEONET 관측소
PGV USGS ShakeMap의 Station List

- 데이터별 전처리**
- ObsPy를 이용해 관측소별 시간순으로 병합
 - E, N, Z(U) 3성분 파형 추출
 - 도호쿠 데이터는 가공 없이 사용
 - 노토 데이터는 ENU 좌표계로 변환 처리
 - 반경 25km 내의 지진파형 관측소와
GNSS 관측소를 하나의 샘플로 구성

지진파형 및 GNSS 공통 전처리


- 본진 발생 시각 기준 전후 45분 구간 제한
- Z-score 정규화
- 윈도우 크기 360초, stride 180초 적용하여 분할
- 지진파형은 100Hz, GNSS는 1Hz의 다른
sampling rate 유지

*GNSS: 위성으로부터의 전파를 이용해 측정된 지표 변위

*PGV(Peak Ground Velocity): 지진 발생 시 지표가 흔들릴 때의 최대 속도


전체 모델 아키텍처

주요 기능 1. 모달리티별 인코더



EQTransformer 구조 차용

주요 기능 2. UMIS 및 디코더




- 공통된 128차원으로 매핑
Modality embedding
Cross modal attention 양방향 적용
→ 지진파형 기준의 **128차원 UMIS feature** 출력

- Attention pooling
2-layer MLP
Regression layer
Vs30 데이터로 지반 증폭 보정

→ 최종 PGV 값 예측

주요 기능 3. 후처리



- PGV 값에 **크리깅(Kriging)** 기법 적용
→ **미계측 지역이 보간된** PGV 분포 생성
생성된 격자 기반 PGV 분포 활용
→ **ShakeMap 형태의 지진 위험지도 생성**

실험 및 결과

	Seismic-only	GNSS-only	Proposed
노토 테스트 실험 Test RMSE	10.96	21.38	9.92
홋카이도 테스트 실험 Test RMSE	8.25	8.93	7.80
쿠마모토 테스트 실험 Test RMSE	4.52	14.05	3.47
도호쿠 테스트 실험 Test RMSE	12.27	8.76	14.05

Seismic-only 및 GNSS-only 대비 RMSE

노토 테스트 실험: 9.5%, 53.6% 감소


홋카이도 테스트 실험: 5.5%, 12.7% 감소

쿠마모토 테스트 실험: 23.2%, **75.3%** 감소

도호쿠 테스트 실험: 14.5%, 60.4% 증가

멀티모달 융합의
유효성 확인

*도호쿠 실험은 PGV 규모가 다른 지진에 비해
PGV 분포가 현저히 커 성능 저하 발생



실험별 ShakeMap 시각화

데모 시연

